



ANÁLISE DE DADOS

Eduardo Ogasawara
eduardo.ogasawara@cefet-rj.br
<https://eic.cefet-rj.br/~eogasawara>

Biografia

- Doutor em Engenharia de Sistemas e Computação (COPPE/UFRJ) em 2011
- Professor no EIC - CEFET/RJ
 - Departamento de Ciência da Computação
 - Curso Técnico de Informática
- Programa de Pós-Graduação em Ciência da Computação (PPCIC)
- Programa de Pós-Graduação em Engenharia de Produção e Sistemas (PPPRO)
- Membro do Sênior da IEEE
- Membro da SBC e ACM





Detecção de eventos

- Data
- Anomalias
- Pontos de mudança/Desvio de conceito
- Motifs
- Detecção online

Predição em séries temporais


- Regressão
- Classificação

Mineração de Dados e IA Centrada em Dados


- Métodos
- Aplicações

Detecção de eventos


- Anomalias
- Pontos de mudança
- Motifs
- Detecção online




Método A: anomalias



Método B: anomalias & pontos de mudança



Método C: anomalias de volatilidade



Métodos A, B & C:
anomalias, anomalias de volatilidade e pontos
de mudança

Harbingers: Um framework para integração e análise de métodos de detecção de eventos em séries temporais*

Roberto Sallós¹, Luciano Escobar², Luis Baroni³, Rocio Zorrilla⁴,
Arnar Zissai⁵, Vladimir Koshlov⁶, Flávia C. Delicato⁷, Paulo E. Pinheiro⁸,
Luciano Maia⁹, Rafaela Cristóvão⁹, Laura Azei⁹, Eduardo Ogasawara⁹

¹CHIFFRE - Centro Federal de Educação Tecnológica Celso Suckow da Fonseca
²LACC - Laboratório Nacional de Computação Científica
³USP - Universidade Federal Fluminense

Paraben

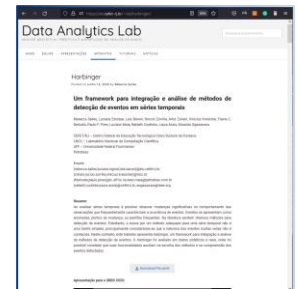
jedern, allen, lichen, nigoli, lala, herculidic, refer-ej.be
latiani, noma, novella, viridus, kuqanor(f)at.be
(f)elicitu, paula girma(f)ic.off.be, lichen, maioparaben.com.be

Abstract. When analysing time series, it is possible to observe significant changes in the behaviour of the observations that frequently characterise the occurrence of events. Events may appear as anomalous, change points, or frequent patterns. In this sense, there are several methods for event detection. However, the search for a suitable method for a time series is not a simple task, especially considering that the nature of the events is often not known. In this context, this paper compares the performance of several statistical and machine learning detection methods. Hantingjie was evaluated with synthetic and real data, where it was possible to verify that its functionalities favour the selection of methods and the understanding of detected events.

Resumo. No estudo sobre temporalidade é possível observar mudanças significativas no comportamento das observações que frequentemente caracterizam a ocorrência de eventos. Então se apresentam como anomalias, pontos de mudança, ou padrões frequentes. Na literatura existem diversos métodos para detecção de eventos. Entretanto, a busca por um método adequado para uma série temporal não é uma tarefa simples, principalmente considerando-se que a maioria dos métodos disponíveis não são capazes de lidar com dados não balanceados. Já o algoritmo Houghing, um framework para integração e análise de métodos de detecção de eventos. O Houghing foi avaliado em dados sintéticos e reais, onde foi possível constatar que mais funcionalidades promovem a seleção de métodos e a compreensão dos eventos detectados.

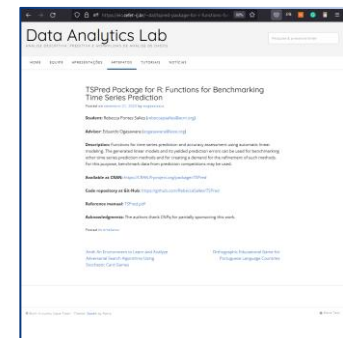
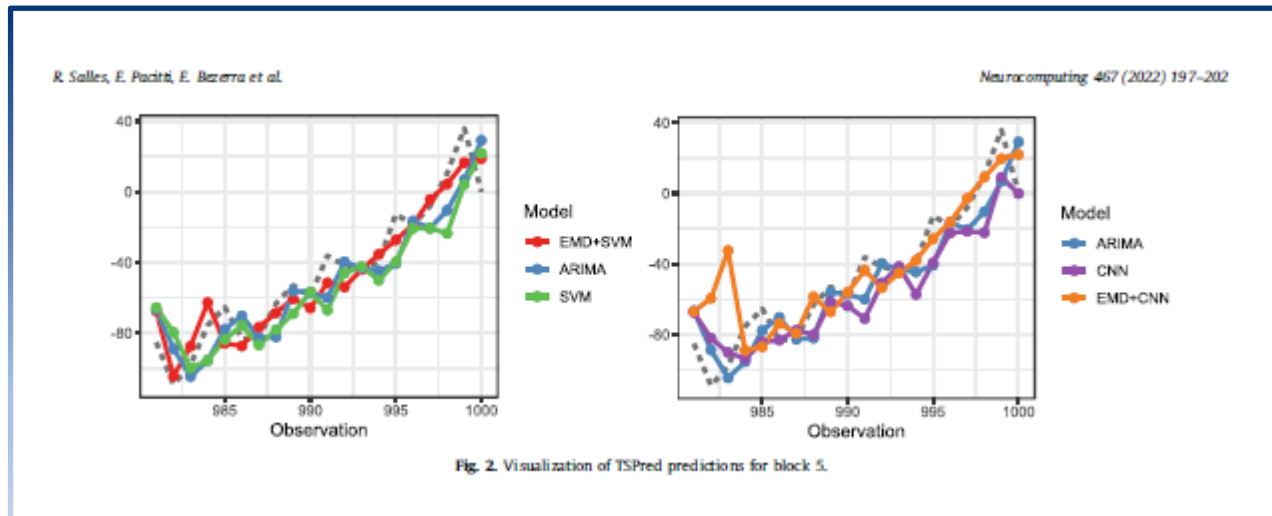
1. Introdução

Na análise de séries temporais, frequentemente é possível observar a ocorrência de uma mudança significativa em seu comportamento em um certo ponto ou intervalo de tempo.



Predição

- Classificação
- Regressão



Event Detection in Time Series



Harbinger

Stars 16 downloads 24K/month

Harbinger is a framework for event detection in time series. It provides an integrated environment for time series anomaly detection, change points, and motif discovery. It provides a broad range of event detection methods and functions for plotting and evaluating event detections.

In the anomaly classes, methods are based on machine learning model deviation (Conv1D, ELM, MLP, LSTM, Random Regression Forest, SVM), machine learning classification model (Decision Tree, KNN, MLP, Naive Bayes, Random Forest, SVM), clustering (kmeans and DTW) and statistical methods (ARIMA, FBIAD, GARCH).

In the change points classes, methods are based on linear regression, ARIMA, ETS, GARCH, AMOC, ChowTest, BinSeg, GFT, PELT.

Data Analytics Lab Team

Doutorado



Ellen Paixão



Janio Lima



Lais Baroni



Lucas Giusti*



Marlon Mesquita

Mestrado



Alexandre Silva



Arthur Garcia



Edson Sobrinho



Fabiana Santos*



Frank Faisca



Igor Andrade



Josélia Rabelo



Luiz Oliveira




Michel Reis*



Rodrigo Machado

Materiais adicionais

- Análise de Dados
- Mineração de Dados
- Programação em R
- Metodologia Científica
- Banco de Dados



The image shows a YouTube channel banner for Eduardo Ogasawara. On the left is a circular profile picture of a man with short brown hair, smiling, wearing a dark shirt. To the right of the picture, the name "Eduardo Ogasawara" is written in large white bold letters. Below the name, the handle "@eduardo.ogasawara" is followed by "759 subscribers · 70 videos". Further down, a line of text reads "Sou professor do Departamento de Ciência da Computação do Centro Federal de" followed by the URL "eic.cefet-rj.br/~eogasawara" in blue. Below this is a white "Subscribe" button. At the bottom left, there are navigation links: "Home", "Videos", and "Playlists", followed by a magnifying glass icon. On the right side of the banner is a large black and white QR code.

Eduardo Ogasawara
@eduardo.ogasawara · 759 subscribers · 70 videos
Sou professor do Departamento de Ciência da Computação do Centro Federal de
eic.cefet-rj.br/~eogasawara
Subscribe
Home Videos Playlists 🔍